

Computer Graphics – Spring 2024

Assignment 1 — Foreground Segmentation and Poisson Blending

Yaniv Mualem 209127612

Ron Mondshein 318895877

[טבלת התוצאות לאלגוריתם Grab-cut](#):




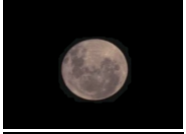



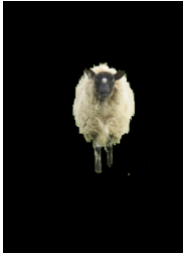






Image name	Accuracy	Jaccard
banana1	0.72025390625	0.4769000401738432
banana2	0.9468977864583333	0.8142809977572094
book	0.8707421875	0.7408601448802454
bush	0.8449185185185185	0.4712797525096281
cross	0.6740888888888888	0.5191160076070562
flower	0.9890703703703704	0.9464185201997276
fullmoon	0.9803684550743375	0.7543873837444399
grave	0.9602925925925926	0.7412761233650272
llama	0.9827661396678279	0.9092116917626218
memorial	0.9780333333333333	0.8880837814888197
sheep	0.9965814814814815	0.9375549692172384
stone2	0.9756803385416667	0.9086172099565776
teddy	0.9798375681223016	0.913768965908661

[זמן התכנסות ממוצע עבור כל תמונה עבור שימוש ב 5 components:](#)

Img name	Run Time in seconds
banana1	173.5922498703003
banana2	248.88053393363953
book	212.4912838935852
bush	249.72815585136414
cross	117.25709795951843
flower	259.30799412727356
fullmoon	74.17144346237183
grave	271.69459891319275
llama	137.30887031555176
memorial	403.6538848876953
sheep	297.81096267700195
stone2	235.88101363182068
teddy	40.653235912323


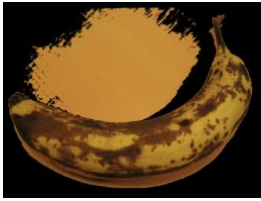
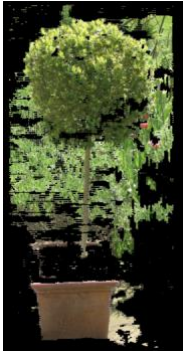







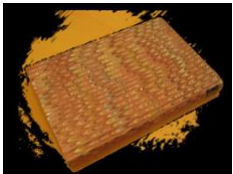
PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING

[מספר דוגמאות לחילוצים טובים של אלגוריתם grabcut:](#)

<u>Name</u>	<u>Before grabcut</u>	<u>After grabcut</u>	<u>Name</u>	<u>Before grabcut</u>	<u>After grabcut</u>
<u>flower</u>			<u>fullmoon</u>		
<u>teddy</u>			<u>sheep</u>		
<u>stone2</u>			<u>memorial</u>		
<u>llama</u>					

נראה כי האלגוריתם הפריד בקלות תמונות בעלות עצם ברור בצבע השונה מהרקע.

[מספר דוגמאות לחילוצים פחות מוצלחים של אלגוריתם grabcut:](#)










<u>Name</u>	<u>Before grabcut</u>	<u>After grabcut</u>	<u>Name</u>	<u>Before grabcut</u>	<u>After grabcut</u>
<u>banana1</u>			<u>bush</u>		
<u>grave</u>			<u>cross</u>		
<u>Banana2</u>			<u>Book</u>		

נראה כי האלגוריתם התקשה במיוחד עם אובייקטים יחסים קטנים כמו החלק של הצלב או הגזע של השיח. כמו"כ ניתן לראות כי האלגוריתם מתקשה להפריד צבעים הדומים אחד לשני כמו במקרה של הבגנה, הספר, בחלק עם הדוגמא בקבר או העלים של השיח.

PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING

[ניתוח השפעת משתנים שונים על תוצאות האלגוריתם](#)

השפעת אפקט ה-blur-

Blur level	without	Low	High
			
Accuracy and Jaccard values	Accuracy= 0.9890703703703704 Jaccard= 0.9464185201997276	Accuracy= 0.9866925925925926 Jaccard= 0.9356358490228042	Accuracy= 0.9651925925925926 Jaccard= 0.8473855147775252
			
Accuracy and Jaccard values	Accuracy= 0.9798375681223016 Jaccard= 0.913768965908661	Accuracy= 0.9709108924906221 Jaccard= 0.8802185792349727	Accuracy= 0.8670730412626513 Jaccard= 0.6165918138205573
Accuracy and Jaccard values			
	Accuracy= 0.6740666666666667	Accuracy= 0.7000259259259259	Accuracy= 0.5659296296296297

PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING


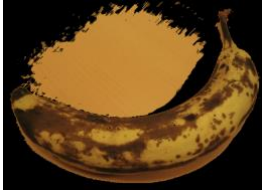
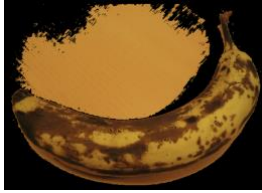
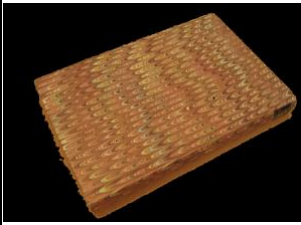
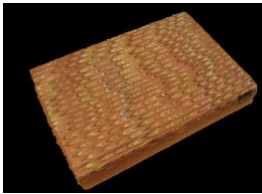
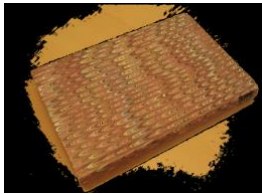
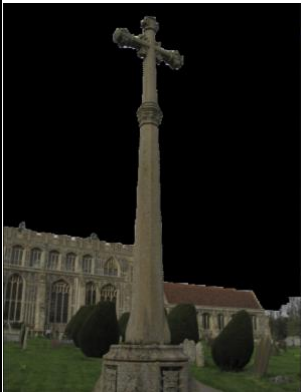


	Jaccard= 0.5190832185717096	Jaccard= 0.5463619000677715	Jaccard= 0.4055730537676947 6
--	--------------------------------	--------------------------------	-------------------------------------

מסקנות:

הערה - בכל דוגמא בטבלה הפעלנו את האלגוריתם על התמונה המטושטשת שיצרנו ואת המסיכה שהתקבלה הפעלנו על התמונה המקורית לצורך הנוחות בהתבוננות על התוצאה.

נשים לב כי הפעלת טשטוש בכל רמה שהיא (נמוכה או גבוהה) הובילה לירידה באחוזי הדיוק של התמונה כך שככל שהטשטוש עלה חלה ירידה בדיוק. ניתן לראות שההשפעה באה לידי ביטוי כך שבעת הוספת טשטוש לתמונה האלגוריתם הוסיף חלק מן המסגרת שמסביב לאובייקט, דבר שעולה בקנה אחד עם הצפיות שלנו, מכיוון שבעת טשטוש התמונה יותר קשה להבדיל בין האובייקט למסגרת שמסביבו ונוצרת שכבה שבה הם מתמזגים אחד עם השני.

לצד זאת, מעניין לראות שבתמונת cross, אמנם חלה ירידה בדיוק, אך הוספת המסגרת עזרה לחלקו העליון של הצלב להיות ברור יותר ויזואלית, זאת כמובן על חשבון הוספת חלק ניכר מהשמיים, כלומר טשטוש התמונה סייע במידה מסויימת לאלגוריתם לזהות את חלקו העליון של הצלב כחלק מהאובייקט, מכיוון שטשטוש התמונה הוסיף נפח מסוים לחלק יחסית צר בו.

Img Name / Components	Banana1 1	Banana1 3	Banana1 9
Image			
Accuracy and Jaccard values	Accuracy= 0.9536002604166667 Jaccard= 0.8465695033476136	Accuracy= 0.7370345052083334 Jaccard= 0.4923490708912783	Accuracy= 0.6998046875 Jaccard= 0.4589488753036152
Img Name / Components	Book 1	Book 3	Book 9
Image			
Accuracy and Jaccard values	Accuracy= 0.9720377604166667 Jaccard= 0.9296426436019035	Accuracy= 0.9733203125 Jaccard= 0.9326546207508566	Accuracy= 0.8534049479166667 Jaccard= 0.715904287868178
Img Name / Components	Cross 1	Cross 3	Cross 9
Image			

PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING

Accuracy and Jaccard values	Accuracy= 0.9855703703703703 Jaccard= 0.9623163453819146	Accuracy= 0.6938777777777778 Jaccard= 0.536939823970688	Accuracy= 0.6793407407407407, Jaccard= 0.5228968512007759
-----------------------------	---	--	--



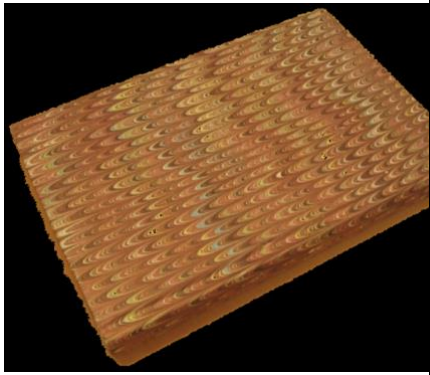
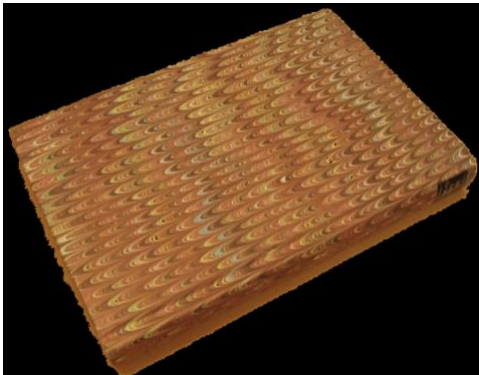
מסקנות:

ניתן לראות שעבור הבננה והצלב ערכי הדיוק והJaccard טובים בצורה ניכרת כאשר מספר הGMMS יורד לGMMS בודד. הערכים הטובים ביותר של הספר מתקבלים עבור 3 רכיבים. ניתן לראות זאת גם לפי הערכים המספריים וגם בצורה ויזואלית מהתמונה עצמה.

ניתן להסיק שכאשר יש לנו תמונה ולה עצם דומיננטי מרכזי, הצורה הטובה ביותר ליצור הפרדה בין האובייקט לרקע היא על ידי הקטנת כמות הרכיבים.

קביעה אידיאלית של מספר רכיבים צריכה להיות באופן אינדיבידואלי לכל תמונה, ולא על ידי בחירת ערך יחיד לכמות תמונות השונות זו מזו כמו במטלה, כך שכאשר יש לנו עצם דומיננטי בתמונה נדע לבחון מספרי רכיבים נמוכים.

[השפעת אתחול המלבן על ערכים שונים:](#)

Img Name / Rect	Banana1 31,120,603,420	Banana1 21,110,613,430
		
Accuracy and Jaccard values	Accuracy=0.9673079427083333 Jaccard=0.8845472938796156	Accuracy=0.96140625 Jaccard=0.8668508473434183
Img Name / Rect	book 73,40,595,450	book 63,30,605,460
		
Accuracy and Jaccard values	Accuracy=0.9734765625 Jaccard=0.9329934210526316	Accuracy=0.9732194010416667 Jaccard=0.932417113002333

מסקנות:

נציין כי ב-2 המקרים בחרנו במלבנים כמה שיותר הדוקים לתמונות השמאליות, ומעט יותר משוחררים לימניות.

ניתן לראות בבירור שהתקבלו תוצאות טובות גם מבחינת הערכי דיוק וגם מבחינת נראות בשני המקרים. בשני המקרים נראה שכלל שהמלבן יותר צמוד לאובייקט הדומיננטי בתמונה ככה נצליח לחלץ את אותו אובייקט בצורה מדויקת יותר. ככה האלגוריתם מתחשב בפחות "רעש רקע" ומגיע לתוצאות טובות יותר.

Poisson Blending report:

בשלב הראשון נציג את תוצאות האלגוריתם בעבור כל תמונה עם mask המתאים שסופק לנו בקובץ הקיץ, אשר הדוק סביב האובייקט -

Name/
Mask

Output


Book



Name

Output


Fullmoon



Banana2



Sheep



Memorial



Llama



PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING

Cross



Banana1



Grave



Bush



flower



stone2



Teddy



PROJECT 1- FOREGROUND SEGMENTATION AND POISSON BLENDING

נציג בעבור 2 תמונות את פלט האלגוריתם עבור mask פחות הדוק מזה שסופק -


Tight
mask

Original output

Less tight mask

New output

Teddy



Banana1



מסקנות:

ניתן להבחין כי כאשר המסכה המשומשת על ידי האלגוריתם אינה צמודה לאובייקט, מתעוררות מספר בעיות : ניתן לראות כי חלקים לא רצויים מהרקע (background) מתערבבים עם האובייקט (foreground), מה שגורם למעבר שאינו טבעי בין השניים ולשכבת "תפר" ביניהם - קו מתאר חלש של הרקע המקורי המקיף את האובייקט. בנוסף לכך, ישנה השפעה גם על התאמות צבע והמרקם הנעשים בולטים יותר וגורמים לאובייקט לבלוט יותר על פני הרקע, דבר שגם הוא בא לידי ביטוי במיזוג פחות טבעי. בעיות אלו מדגישות את החשיבות של שימוש במסכה מדויקת וצמודה למיזוג פואסון איכותי.